Pi0.5 内部 VLM 语言探针报告

将动作专家排除后，对已部署的 Pi0.5-LIBERO 检查点进行 100 题直接文本生成消融

结论：100/100 次直接生成调用均成功返回 token
序列，但没有一条形成可读英文回答。在固定真实仿真画面、标准 PaliGemma
问答提示和贪心解码下，三类问题的清洗后英文词数均为 0；这支持“ 该动作微调后内部 VLM
不应被当作普通聊天式 VLM/LLM 使用 ”的工程结论。

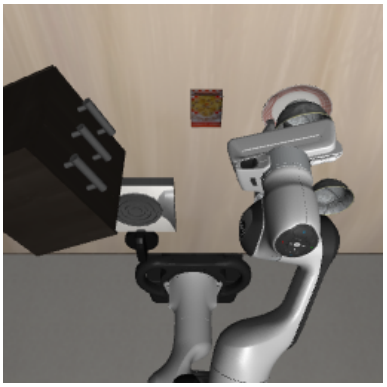
实验对象	已部署 `lerobot/pi05_libero_finetuned` 的内部 `PaliGemmaForConditionalGenerationWithPiGemma`
不参与的模块	300M action expert、flow-matching 动作采样器、7D action 输出
输入	同一张 LIBERO `agentview` 相机帧；策略内部规格 224×224，14px patch，共 256 image tokens
问题与解码	100 个英文问题；`<image>answer en {question}`；贪心解码；最多 32 new tokens
结果	100 成功 / 0 接口错误 / 100 条不同文本串 / 0 条可读英文回答
运行环境	NVIDIA GeForce RTX 4090 D；PyTorch 2.11.0+cu128；CUDA 12.8；总墙钟 152.33s

这次究竟测了什么？

Pi0.5 是视觉—语言—动作（VLA）策略，而不是一个“ VLM 加一个可随时拔掉的动作头 ”。它在策略路径中把图像、任务语言、状态和动作流结合，正常目标是预测连续动作。本实验刻意绕开策略的 `sample_actions`，只调用内部 PaliGemma 流的 `generate`；因此这是一个有用但非官方支持的能力消融，不是对 Pi0.5 正常机器人性能的测量。

与已有 LIBERO 基线的关系

此前 392/400（98.0%）的 LIBERO 结果使用的是正常 `sample_actions` 策略路径：原始 256×256
相机画面先在策略内部预处理为 224×224，随后进入动作流。本报告的文本探针没有修改该基线，也没有重新训练或覆盖任何权重；它仅验证“ 能否把内部 VLM 当普通问答模型 ”的不同问题。



固定视觉上下文：LIBERO smoke 的 agentview 帧（SHA-256 前缀：762a2e30…）

实验协议与可复现性

模型边界。运行时加载的是项目本地 checkpoint，并取 `policy.model.paligemma_with_expert.paligemma`。生成调用未访问 `gemma_expert`，也未调用 flow-matching、动作反归一化或环境 step。为兼容该 OpenPI 端口与当前 Transformers，实验明确对齐了图像 special token id（257152）；这是输入接口适配，不是权重修改。

图像规格。仿真输出的相机帧确实是 256×256；但 checkpoint `config.json` 的 `image_resolution` 为 [224, 224]。前期把原始尺寸直接喂给 SigLIP 时得到 324 vs 256 position-embedding 错误，随后按已加载 checkpoint 的视觉塔规格修正为 224×224 / 256 image tokens。最终 100 题运行接口错误为 0。

问题设计。视觉理解 35 题、一般语言 35 题、机器人推理/操作 30 题。所有题目都保留同一视觉帧，因为被测模块是 VLM；其中“ 一般语言 ”应理解为“ 带固定视觉上下文的一般语言问题 ”，不是严格的纯文本 LLM 基准。

关键命令（服务器端）

```
.venv/bin/python scripts/probe_pi05_vlm_language.py --checkpoint checkpoints/lerobot-pi05-libero-finetuned --image outputs/smoke/image.png --processor assets/paligemma-processor --output-dir outputs/vlm_probe/full_100_20261019 --limit 100 --max-new-tokens 32
```

依赖与原始结果

PaliGemma processor/tokenizer 仅下载到服务器 `assets/paligemma-processor/`，使用 `hf-mirror.com`，未下载基础模型权重。原始逐题 JSONL 为 `outputs/vlm_probe/full_100_20261019/results.jsonl`，大小 96,535 bytes，SHA-256：`95ef03885b1785bf0b2109ebf77f7d1c39d12e87441e3c508c8f3b5c238728c3`。每行包含问题、prompt、原始 token id、原始/清洗文本、耗时与自动指标。

冷加载与生成速度

总墙钟 152.33 秒。首次模型构建与权重重映射约两分钟，符合项目中正常 Pi0.5 策略冷启动记录；加载完成后的单题生成平均 0.320 秒、中位数约 0.302 秒。完成后 GPU 已回到 0% 利用率。

量化结果

自动指标不试图把乱码“强行判成语言”，而是只报告可重复、可检查的表面性质。英文词由正则 `[A-Za-z]+` 计数；ASCII 字母比例在非空白字符中计算；4-gram 重复用于标示明显重复模式。

问题类别	题数	接口成功	平均 token	平均英文词	平均 ASCII 字母率	4-gram 重复
视觉理解	35	35/35	32.0	0.0	0.000	5
一般语言	35	35/35	32.0	0.0	0.000	0
机器人推理	30	30/30	32.0	0.0	0.000	6
总计	100	100/100	32.0	0.0	0.000	11

一眼解读

- 调用可靠性：100 次均返回，说明最终的 224px/256-token 直接生成接口接法是可运行的。
- 文本可读性：100 条清洗结果的英文词数均为 0，ASCII 英文字母率均为 0；因此不存在任何可读的英文问答证据。
- 非恒定错误：100 条完成文本均不同，且部分有重复片段；这更像一个在异常目标分布上进行的确定性 token 解码，而非一个固定 API 错误消息。
- 上限效应：所有样本到达 32-token 截断上限，不能据此断言模型一定永不产生 EOS；但在相同固定上限下，它没有产生可读答案。

代表性原始输出

类别 / 问题	直接 VLM 解码（token id，32 token 上限）
视觉理解 / What objects are visible in this image?	前 16 个生成 token id（共 32 个）：255623 255700 255470 255700 255701 255635 255701 255701 255701 255587 255682 254403 255682 255171 255682 255320
一般语言 / What is 2 plus 2?	前 16 个生成 token id（共 32 个）：255679 255514 255694 255701 255694 255472 255694 255494 255701 255701 255701 255409 255404 255579 255697 255664
机器人推理 / What is the first safe step before picking up an object?	前 16 个生成 token id（共 32 个）：255693 255701 255701 255701 255701 255668 255331 255694 255623 255701 255701 255395 255705 255425 255551 255692

解释边界与下一步

可以得出的结论。在本报告的精确协议下，已部署 Pi0.5-LIBERO checkpoint 的内部 PaliGemma 流不提供可用的英语视觉问答或一般问答输出。所以工程上不应把它拆出来充当 LLM/VLM 聊天机器人；它仍可在原生 VLA 策略路径上获得很高的 LIBERO 动作成功率。

不能过度外推的结论。这不证明预训练时的 PaliGemma “ 完全没有世界知识 ”，也不证明任何不同 checkpoint、不同提示模板或不同解码策略都会失败。本 checkpoint 经 VLA 任务微调，且 `generate` 不是作者承诺的产品接口。更准确的说法是：其直接文本 logit 分布在这套受控探针下不再对齐自然语言。

为何会出现这种现象？

Pi0.5 的训练与推理目标是将视觉、语言任务指令、状态与噪声动作联合用于预测连续动作；它不以 “ 用户问题 → 文本回答 ” 为优化目标。动作微调、特殊 policy prompt/attention 结构，以及 “ 最终只监督 action ” 都会使直接从词表 logits 贪心采样与普通 VQA 的目标失配。这与附件中 “ π0-VLM 直接问答出现乱码 ” 的观察一致，但本实验以自己的 100 条实际输出为证据，而非假定该结论。

建议的后续实验

1. 保留动作能力主线：继续用正常 Pi0.5 policy 路径做多 seed、失败轨迹和 sim-to-real 前的安全验证。
2. 对照组：在完全相同图像与问题上运行受支持的原始 PaliGemma VLM（单独许可与权重），再比较自然语言指标；不要把它与 Pi0.5 动作成功率混为一谈。
3. 专门语言头：若需要机器人解释/问答，使用独立 VLM/LLM 作为上层 planner 或 captioner，而让 Pi0.5 专注低层动作；通过结构化子任务或安全约束衔接，而不是直接解码动作策略的内部 token。
4. 更严谨探针：后续可加入多图、多 seed、不同 prompt、不同 temperature 与 token-level likelihood；但要预注册协议，避免选择性展示乱码样本。

交付物与版本记录

代码：`scripts/probe_pi05_vlm_language.py`；最小处理器下载脚本：`scripts/download_paligemma_processor.sh`；原始输出：`outputs/vlm_probe/full_100_20261019/`；本报告将与 README、PROJECT_MEMORY 一同提交到 GitHub 项目仓库。实验脚本提交链包含 `5d86e61`、`2a63308`、`7da51d8`、`581c4c2`、`5c8800e`、`b80b828`。